

UNSUPERVISED LEARNING

K-Means clustering

```
from sklearn.cluster import KMeans  
mod = KMeans(n_clusters=N)  
mod.fit(data)
```

→ Buscar el centro de los clusters → `mod.cluster_centers_`

→ Hay que minimizarlo sin var. muchos clusters

Usando la misma (como de siempre) entre los datos → `mod.predict()`

Para evaluar un cluster →

Si transformo los datos con `StandardScaler` funciona mejor para clusterizar

```
from sklearn.preprocessing import StandardScaler  
scaler = StandardScaler()  
scaler.fit(samples)  
standard_scaled_samples = scaler.transform(samples)  
samples_scaled = scaler.transform(samples)
```

Visualizaciones para unsupervised learning

Hierarchical clustering

```
from scipy.cluster.hierarchy import linkage, dendrogram  
merging = linkage(samples, method='complete')  
dendrogram(merging, labels=..., leaf_rotation=90, ...)  
plt.show()
```

→ Se interpreta como la distancia entre 2 clusters

Para sacar clusters a partir de una altura del dendrograma →

```
from scipy.cluster.hierarchy import fcluster  
labels = fcluster(merging, distance, criterion='distance')
```

t-SNE

```
from sklearn.manifold import TSNE  
mod = TSNE(learning_rate=100)  
transformed_data = mod.fit_transform(samples)  
xs = transformed_data[:, 0]  
ys = transformed_data[:, 1]  
plt.scatter(xs, ys)
```

Dimension Reduction

PCA → 'Principal Component Analysis'

→ Reduce la dimensionalidad
→ Eliminar la redundancia
→ Centr los datos a los ejes

```
from sklearn.decomposition import PCA  
mod = PCA()  
mod.fit(samples)  
transformed_samples = mod.transform(samples)
```

→ Los principales componentes → direcciones de la varianza

↓
Por tanto → `mod.components_`

→ Si a menudo, los resultados son ambigüos.

Para identificar dimensiones intrínsecas (mínimo por default)

Se puede ver a partir de la varianza de las features de PCA

```
pca = PCA()  
pca.fit(samples)  
features = pca.components_  
variances = pca.explained_variance_
```

Para reducir la reducción →

`PCA(n_components=N)` → fuerza que a 1 Varianza 1 componente

Si es Sparse (datos raros) → `TruncatedSVD(n_components=N)`
↓
`csf_matrix`

UNSUPERVISED LEARNING

Caso PCA
pero nos interpretale

Dimension Reduction

NMF → 'Non-negative matrix factorization' →

Limitación → $\text{klases} \geq 0$

```
from sklearn.decomposition import NMF
nmf = NMF(n_components = N)
nmf.fit(samples)
nmf_transform = nmf.transform(samples)
```

Sistemas de recomendación con NMF

PASO 1 → Uso NMF por obtener features →

```
nmf = NMF(n_components = ...)
nmf_features = nmf.fit_transform(samples)
```

PASO 2 → Comparación entre features →

```
from sklearn.preprocessing import normalize
nmf_features = normalize(nmf_features)
df = pd.DataFrame(nmf_features, index = titulos)
nmf_act = df.loc[:, '...']
similarities = df.dot(nmf_act)
similarities.alexand() →
```

Calcular la distancia coseno con el resto de valores del dataframe

Artículos similares