

# EXPLORATORY DATA ANALYSIS

## Exploración inicial

`.head()` y `.info()`

Para variables categóricas, ver categorías y cuenta `.value_counts()`

`.describe()`

Ver variables numéricas con histogramas

## Data Validation

Para ver únicamente los tipos de datos `books.dtypes`

Convertirlos al tipo deseado

Para cambiar `books['col'].isin(['valor_A', 'valor_B'])`

→ Por cada fila retorna true si el valor está en la lista.

Para ver solo las columnas numéricas `books.select_dtypes(include='number')`

## Neteando datos en los nulos

Para ver la cantidad de valores nulos en cada columna `df.isna().sum()`

Para encontrar el nivel de valores nulos por columna nula `df.isna().sum()`

threshold = len(df) \* 0.95  
cols\_to\_drop = df.columns[df.isna().sum() > threshold]  
df.dropna(subset=cols\_to\_drop, inplace=True)

## Convirtiendo y analizando datos categóricos

Para comprobar si una fila contiene solo 0 o 1 `df['col'].str.contains("0|1")`

Para encontrar múltiples filas `df['col'].str.contains("0|1")`

categorías = ['A', 'B', 'C', ...]  
conditions = [df['col'].str.contains('A'),  
 df['col'].str.contains('B'),  
 ...]  
df['New\_col'] = np.select(conditions, categorías, default='Other')

Deben estar en el mismo orden

## Trabajando los outliers

Preguntas → ¿Por qué está?

✓ ¿Están bien los datos?

# EXPLORATORY DATA ANALYSIS

## Patrones temporales

Para extraer datos de un datetime →

```
df['col'].dt.month  
"      .dt.year  
"      .dt.day
```

## Correlacion

→ usar el coeficiente de Pearson

```
df.corr()
```

## Consideraciones para datos categoricos

Para ver el porcentaje de cada categoria →

```
df['col'].value_counts(normalize=True)
```

Para agregar valores vacios como 0 →

```
pd.crosstab([place['Solido'], place['Deshidro'], value = place['Piso'], aggregate='median')
```